全国高校 AI Web 开发挑战赛 · A 组

灵犀洞察 · LingXi Insight

AI 原生对话式数据分析平台 —— 技术文档

参赛赛事	2026 第九届传智杯全国大学生数智创新与 AI 应用大赛
参赛赛道	AI WEB 网页开发挑战赛（A 组）
团队名称	灵犀洞察队
文档版本	v1.0
技术栈	Next.js 14 · React 18 · TypeScript · Tailwind · Zustand

灵犀洞察 —— AI 原生对话式数据分析平台 · 技术文档

> 全国高校 AI Web 开发挑战赛 · 技术文档（PDF 内容稿）
> 对应命题方向：AI 数据分析与可视化（兼融 AI Agent、RAG、多模态交互）

---

1 项目概述

1.1 背景与问题定义

数据分析是高校学生、中小企业运营人员与基层公务人员的常见需求，但传统路径存在明显门槛：需要掌握 SQL 或 BI 工具、理解数据表结构、手工配置图表。与此同时，大语言模型与 Agent 技术在 2026 年已趋成熟，「用自然语言直接与数据对话」成为可能。

本作品回答一个问题：能否让一个不懂技术的用户，在三句话内完成一次专业的数据分析？

1.2 产品定位

灵犀洞察是一款 AI Native 的对话式数据分析平台。核心特征：

1. **AI 是核心而非附属**：意图理解、查询构造、图表选型、洞察生成全部由 AI 完成；
2. **过程透明**：Agent 的每一步规划、工具调用与执行结果对用户可见、可审计；
3. **结果可信**：所有数字来自服务端真实计算，预测类输出明确标注演示属性。

1.3 目标用户

- 高校学生（课程作业、科研数据处理、学情分析）；
- 中小企业运营、个体经营者（销售数据快速洞察）；
- 需要快速理解数据的教育、公共部门基层人员。

---

2 需求分析

2.1 用户故事

角色	场景	期望
学生	拿到一份课程成绩 CSV	上传后直接问「哪个学科挂科率最高」
运营	每日销售明细	「近30天销售额趋势」「各品类占比」一句话可得
管理者	季度复盘	一键生成结构化洞察报告并导出
研究者	上传文献资料	就文档内容提问并获得带引用的答案

2.2 功能需求

- FR1 数据接入：内置示例数据 + CSV 上传（自动类型推断）；
- FR2 自然语言查询：覆盖趋势、占比、排名、对比、相关性、异常、预测、报告八类意图；
- FR3 可视化：按数据形态自动推荐图表类型；
- FR4 可解释性：Agent 过程可视化；
- FR5 知识库：文档入库、切片、检索、带引用问答；
- FR6 多模态输入：语音转写；
- FR7 报告导出：Markdown 报告生成与下载；
- FR8 安全可控：输入护栏、生成中断、异常降级。

2.3 非功能需求

- 首屏加载 ≤ 200KB（工作台 121KB First Load JS）；
- 流式首包延迟 < 1s；
- 无后端数据库依赖即可完整运行；
- API Key 零硬编码；
- 响应式（桌面三栏 / 移动端抽屉）。

---

3 系统架构设计

3.1 总体架构

采用四层架构（详见 README 架构图）：

1. **用户界面层**：Next.js 14 App Router + React 18 + TypeScript + Tailwind CSS；
2. **交互协议层**：SSE 单向流 + 统一 `AgentEvent` 事件协议；
3. **AI 引擎层**：ReAct 编排 + 双通道（本地演示引擎 / OpenAI 兼容通道）+ 共用工具层；
4. **数据层**：内存数据集 + TF-IDF 倒排索引 + 统计算法。

3.2 关键设计决策

决策	选项	选择理由
框架	Next.js 14 vs Vite SPA	竞赛推荐首选；需要 API Routes 承载 AI 服务端逻辑与 SSE
流式协议	自研 SSE vs Vercel AI SDK	自研事件协议结构更清晰、可完整展示「思考过程」；无 SDK 版本锁定，协议即文档
图表	自研 SVG vs Recharts	零依赖、包体小；可精确实现预测虚线、异常标注等竞赛特色视觉
AI 通道	仅真实 API vs 双通道	保证无 Key 环境下完整可评审；配置 Key 后无缝升级生产级
状态管理	Zustand vs Redux	轻量、无样板代码、TS 友好

3.3 数据模型

- `DatasetPayload`：columns（名称 + 类型）+ rows（Record）；
- `AgentEvent`：10 种事件的判别式联合（详见 `lib/types.ts`）；
- `ChatMessage`：内容块列表（text / metrics / chart / table / citations / report / error）。

---

4 AI 技术方案

4.0 AI 技术选型、集成方式与优化策略

4.0.1 选型理由

技术环节	本作品选型	选型理由
LLM 接入协议	OpenAI Chat Completions 兼容协议（含 Function Calling）	事实工业标准；DeepSeek / 智谱 GLM / 通义千问 / Kimi 均提供兼容端点，一套代码可换多家模型，避免厂商锁定
实际模型	`deepseek-chat`（已接入实测），可替换为 gpt-4o-mini / glm-4-plus / qwen-plus	中文指令遵循能力强、Function Calling 稳定、成本低；且实测其 API 支持 CORS 并允许 `Origin: null`，使单文件版可浏览器直连
编排范式	ReAct（规划 → 工具调用 → 观察 → 生成）	相较一次性问答，可分多步取数并交叉验证；每一步天然可事件化，是实现「AI 过程透明」这一核心设计目标的必要前提
检索方案	自研 TF-IDF + 余弦相似度	零外部依赖、可离线运行、毫秒级响应；接口与 Embedding 检索对齐，后续可平替向量数据库而无需改动上层
流式协议	自研 SSE + 统一 `AgentEvent`	相比 SDK 黑盒封装，自主协议结构清晰、可扩展，「协议即文档」，是过程可视化的通信基础
可视化	自研纯 SVG 图表引擎	零图表库依赖、包体零增量；可精确控制预测虚线、异常标注等竞赛特色视觉

4.0.2 集成方式

1. **工具层统一**：本地演示引擎与真实 LLM 通道共用 `lib/ai/tools.ts` 中同一份工具定义与实现（`TOOL_DEFS` / `executeTool`），两条通道产出结构完全一致，前端无需任何分支处理。
2. **服务端代理**：LLM 调用发生在 Next.js API Route 内，API Key 仅通过环境变量注入，浏览器全程不可见；`GET /api/config` 只回传模型名，不回传密钥。
3. **事件归一化**：LLM 的 `delta` / `tool_calls` / `usage` 统一转换为 `AgentEvent` 后下发，前端渲染管线对本地引擎与真实模型无差别。
4. **浏览器直连（单文件版）**：实测 DeepSeek API 支持 CORS 且允许 `Origin: null`，密钥仅存于 localStorage，HTML 文件本身零密钥，可安全传阅。
5. **通道热切换**：应用内提供「自动 / 真实模型 / 本地演示」三档，路由按 `channel` 决策，未配置 Key 时给出配置指引并自动回退本地引擎。

4.0.3 优化策略

优化点	待解决问题	采取策略	实测效果
Token 成本	原始数据全量入 Prompt 成本高	仅注入 Schema（字段名 + 类型 + 少量样例）与聚合结果，原始行不进模型	单次对话 token 量降至约 1.8k
事实准确性	LLM 易编造数字	所有数值由服务端 `executeTool` 真实计算后回注，Prompt 明令禁止编造	统计数字 100% 真实可复现
图表缺失	LLM 可能只调 `query_data` 而不调 `recommend_chart`	工具循环内自动补全图表（`chartEmitted` 去重）	图表覆盖率 100%
用量统计	按字符估算偏差大	`stream_options.include_usage` 读取 API 精确值	usage 精确（如 1787/386、1949/556）
首包延迟	等待完整响应体验差	SSE 逐事件推送，思考步骤先行渲染	流式首包 < 1s
服务可用性	API 不可用导致演示中断	通道异常自动降级本地引擎并明确告知用户	演示 0 中断
循环失控	工具调用可能死循环	工具调用轮次上限 6	成本可控
检索噪声	低相关度文档误导回答	相关度阈值 0.08，未命中即回退数据分析通道	引用可信可核查
预测误导	用户可能误信预测结果	所有预测输出固定标注「演示性预测，仅供参考」	责任边界清晰

4.1 意图理解（规则 + 同义词映射）

`classifyIntent` 基于优先级关键词匹配识别 10 类意图；
`parseQuery` 将问题解析为结构化 `QuerySpec`：指标（列名 + 同义词）、维度、聚合方式、时间范围（最近 N 天 / 本周 / 上月 / N 年）、时间粒度（日/周/月）、Top N、维度值过滤（含前缀模糊匹配）。解析失败时进入「澄清引导」而非猜测。

4.2 数据查询引擎

`queryData` 执行：行过滤（时间范围 + 维度值）→ 分组（时间分桶 / 类别）→ 聚合（sum/avg/max/min/count）→ 排序 → Top N 截断，输出图表序列、表格、指标卡与统计量（总计、均值、峰谷、环比变化）。上一周期对比通过日期平移窗口真实计算。

4.3 Agent 编排（ReAct）

规划 → 工具调用 → 观察 → 生成。深度思考模式追加「数据质量检查」与「交叉验证」步骤；异常/预测/相关性意图追加对应专用工具。全过程以事件流输出，前端实时渲染。

4.4 工具集（Function Calling）

工具	算法	输出
query_data	分组聚合	序列 + 表格 + 指标卡
recommend_chart	数据形态 → 图表类型	ChartSpec
detect_anomaly	Z-Score（阈值 1.8）	异常点 + 标注序列
forecast	最小二乘线性回归	预测虚线序列
analyze_correlation	Pearson r	散点 + 相关系数
search_knowledge	TF-IDF 余弦	引用列表

4.5 RAG 知识库

切片（160/40 滑动窗口，标点优先）→ 分词（中文二元组 + 英文词）→ TF-IDF →
余弦相似度 Top-3 → 抽取最相关句子作为引用。相关度阈值 0.08，未命中即回退数据分析通道。
接口与 Embedding 检索对齐，可平替向量数据库。

4.6 真实模型接入

配置 `OPENAI_API_KEY` 后切换至 OpenAI 兼容通道：系统提示词注入数据 Schema 与工具规范，
流式接收 LLM 输出，累积 tool_calls 后本地执行并回注，循环直至无工具调用（上限 6 轮）。
异常时自动降级本地引擎，保证评审演示不中断。

4.7 Prompt 设计要点

角色约束（数据分析助手）、Schema 注入（字段名与类型）、工具使用规范
（指标维度必须真实存在、口语映射、禁止编造数字）、输出结构（结论→依据→建议）、
预测免责声明、安全边界。

---

5 核心功能实现

5.1 流式渲染管线

`fetch` → `ReadableStream` reader → 按 `\n\n` 切分 SSE 帧 → JSON 解析 → 事件分发：
`text` 增量追加至末尾文本块（配合打字光标），`tool_result` 推送图表/指标/表格内容块，
`tool_call/result` 更新追踪面板（含真实耗时）。`AbortController` 支持随时中断。

5.2 纯 SVG 图表引擎

- 折线：`pathLength=1` + dashoffset 实现描线入场动画；面积渐变；预测序列虚线；
  异常点脉冲圆环；`<title>` 原生 tooltip；
- 环形：极坐标弧路径 + 中心汇总值 + 图例百分比；
- 条形/水平条形：`transform-box: fill-box` 实现生长动画；
- 散点：双轴 nice-scale 刻度；
- 「好看」的刻度算法：基于数量级的 step 取整（1/2/5×10^n）。

5.3 CSV 上传与类型推断

PapaParse 解析 → 每列抽样 50 值 → 全数值 / 全日期 / 文本三态推断 →
值强转（数字 parseFloat、日期归一化 YYYY-MM-DD）→ 上限 5000 行防护。

5.4 报告生成

`composeReport` 汇总：数据概览（行列数、时间范围、维度基数、指标统计表）、
核心发现（整体表现、峰谷、结构集中度、指标相关性）、月度趋势、行动建议、
会话问题回顾；以 Markdown 流式输出，前端轻量渲染并支持下载。

5.5 响应式与可访问性

桌面三栏（数据源 288px / 对话自适应 / 追踪 320px）；移动端侧栏抽屉、右栏 Tab 隐藏；
`prefers-reduced-motion` 降级所有动画；语义化标题与 aria-label。

---

6 测试与部署

6.1 测试

- **类型安全**：`tsc --noEmit` strict 模式零错误；
- **端到端测试**（`scripts/e2e-test.mjs`，13 项断言全部通过）：
  趋势/占比/排名/对比/预测/异常/相关性/报告/问候/护栏十条对话路径 +
  RAG 引用 + `/api/rag` 检索接口 + `/api/report` 报告接口；
- **构建验证**：`next build` 通过，6 路由，工作台 First Load JS 121KB；
- **真实计算校验**：所有断言中的数字均由查询引擎现场计算，测试数据为种子生成可复现。

6.2 部署

标准 Next.js 应用，支持 Vercel / Node 服务器 / Docker 部署：

```
npm install && npm run build && npm start   # 默认 3000 端口
```

无外部服务依赖（数据库/对象存储均不需要）；SSE 已禁用代理缓冲
（`X-Accel-Buffering: no`）。

---

7 创新点说明

7.1 技术创新点

1. **统一事件协议的双通道 AI 架构**：本地确定性引擎与真实 LLM 通道共用同一工具层与同一
   `AgentEvent` 协议，通道可热切换、异常自动降级，实现「零 Key 可评审、有 Key 即生产级」，
   在同一套前端代码下同时满足评审可复现性与生产级智能。

2. **AI 思考过程全透明（ReAct 可视化）**：规划步骤、工具调用参数、执行耗时、观察摘要全程实时呈现并附带 token 用量，将黑盒推理转变为可审计、可教学的透明过程。
3. **自研纯 SVG 图表引擎**：零图表库依赖，精确实现预测虚线、异常点脉冲标注、基于数量级的 nice-scale 刻度算法、描线/生长入场动画与原生 tooltip，可视化能力完全自主可控。
4. **Schema 注入 + 服务端真算的防幻觉链路**：模型只见 Schema 不见原始行，所有数值由服务端计算后回注，从架构层面而非提示词层面消除数值幻觉。
5. **浏览器端完整 Function Calling 工具循环**：单文件版在浏览器内实现 SSE 流式解析、`tool_calls` 累积、工具本地执行与图表补全，无服务端亦可跑通 Agent 全链路。

7.2 应用创新点

1. **三句话完成一次专业数据分析**：面向不懂 SQL 与 BI 工具的用户，自然语言直达「图表 + 指标卡 + 解读 + 报告」，显著降低数据分析门槛。
2. **带可溯源引用的知识库问答**：文档入库后回答附引用片段与相关度评分，结论可核查、可回溯，避免无依据生成。
3. **零安装单文件交付形态**：约 165KB 的单个 HTML，双击即运行、可离线、可传阅、可直接用于课堂教学分发，交付与评审成本极低。
4. **可控的多模态交互体验**：语音输入、一键中断生成、报告一键导出、输入安全护栏与降级提示，覆盖真实工作场景中的可控性与可靠性需求。

---

8 总结与展望

8.1 总结

本作品以「AI 过程透明化」为核心设计理念，构建了完整的 AI Native 数据分析应用：
统一事件协议实现前后端解耦，双通道 AI 引擎兼顾可评审性与生产级能力，
自研 SVG 图表引擎实现零依赖的可视化，RAG 与安全护栏完善了 AI 应用的可靠性。
13 项端到端测试全部通过，全部统计数字真实可复现。

8.2 不足

- 本地引擎的解读文本为模板化合成，个性化程度依赖真实模型；
- 预测为线性外推，未建模季节性；
- 数据集未持久化，刷新后恢复初始状态。

8.3 展望

接入向量数据库实现语义级 RAG；引入季节性预测模型；扩展多 Agent 协作（分析/图表/报告 Agent）；增加数据持久化与团队协作看板。

本文档由参赛团队编写，对应仓库 `lingxi-insight/`，可通过 README 中的演示脚本逐项复核。